




MINICURSO – MACHINE LEARNING (ML)

IGOR BRAGA, IGOR MARTINELLI E MATEUS PEDRINO



QUEM SOMOS



QUEM SOMOS



Empresa líder
em **Data**
Science para
Business
Performance
no Brasil



Inteligência Artificial
+
visão de business
+
massa enorme de dados
=
resultados mensuráveis
na ponta



Equipe de PhDs
e mestres
gerando
inovação na
fronteira do
conhecimento



Portfolio de
produtos com
foco em KPIs
de resultado
em vendas e
marketing



“Walk the walk”:
relacionamentos de
longo prazo em que
só ganhamos se o
cliente tem ganho
comprovado

**SEM GUESSING,
SEM SUBJETIVIDADE:
100% QUANTI**



ALGUNS DE NOSSOS CLIENTES



ambev



oBoticário



magazineluiza
vem ser feliz





Previsão de venda de
revistas em bancas

Venda consignada: não vendeu, editora recolhe,
gerando prejuízo

Criamos modelo para prever a quantidade de revistas
que seriam vendidas em cada banca

Modelo vivo: a cada semana os resultados da
semana anterior eram alimentados ao modelo

Resultado: redução de **64%** no encalhe, sem perda
significativa de vendas



Recomendação de produtos no mundo real

Problema I: alguns produtos-chave incentivados em toda a base de PDVs*, outros a critério do vendedor

Problema II: vendedor possui a inteligência sobre o PDV. O que acontece se ele sai?

Criamos modelo para sugerir produtos e quantidades a cada visita, baseado em PDVs semelhantes

Resultado: aumento de lucro de **12%** nas áreas em que o projeto foi empregado

*pontos de venda



Precificação em rede
de farmácias.

**Ganhos apurados na
casa de 7 dígitos.**

Objetivo: encontrar o **preço ótimo** de 14.000 SKUs
em cada uma das 400+ lojas da rede de farmácias

Precificamos tanto SKUs **Farma** quanto **não-Farma**:
linha capilar, higiene bucal, desodorantes, fraldas etc.

Último mês: grupo de tratamento (Big Data precifica)
obteve **lucro bruto 4,4% maior** que grupo de controle



O QUE FAZEMOS



TEMOS MAIS DE 17.000 VARIÁVEIS

ALGUNS DOS DADOS GEORREFERENCIADOS PARA ANÁLISE

- Renda (algoritmo propr. → atualização mensal)
- Emprego
- Clima
- Educação Básica e Superior
- Tweets (> 2 bilhões), Facebook
- Saúde
- Frota e emplacamento de carros
- Religião

- Transporte coletivo
- 27 milhões de CNPJs
- Antenas de telefonia celular
- Criminalidade
- Perfil ideológico
- Densidade demográfica
- Padrões de trânsito
- Preços de 20.000+ SKUs em supermercados

NOSSOS PRODUTOS



PRICEO

- Encontrar o preço ideal por SKU em cada PDV, que maximiza lucro ou vendas
- Big data analytics + behavioral economics = ferramenta viva, constantemente melhorada



ONE-CLICK ORDER

- Determinar o sortimento ideal por PDV, com SKUs e quantidades
- Auto-calibrado constantemente
- Descubra e antecipa demanda do cliente final



OPTIMARC

- Marketing Mix Optimization
- Incorpora budget inteiro: mídia e trade
- Dashboard online com simulações real-time para praça, mídia e veículo



TARGETOM

- Definição de meta de faturamento ou lucro por PDV
- Levando em consideração variáveis do local em que PDV está inserido


AGENDA



- 1 Histórico
- 2 Tipos de Machine Learning
- 3 Aprendizado Supervisionado
- 4 Overfitting e Underfitting
- 5 Perceptron Multicamadas
- 6 Árvores de Decisão




HISTÓRICO



PERCEPTRON

- Surgiu em 1958
- Desenvolvido por Frank Rosenblatt
- Finalidade: reconhecimento de padrões
- Baseado no modelo neural de McCulloch & Pitts
- Simulado em software, primeiramente
- Depois, virou hardware: *Mark I Perceptron*



ARCHIVES | 1958

NEW NAVY DEVICE LEARNS BY DOING; Psychologist Shows Embryo of Computer Designed to Read and Grow Wiser


SPECIAL TO THE NEW YORK TIMES JULY 8, 1958



WASHINGTON, July 7 (UPI) -- The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.



PERCEPTRON






$$y = g \left(\sum_{n=1}^d x_n w_n \right)$$

Implementa superfície de
separação linear

PERCEPTRON

- Limitado à separação linear
- Não reconhece padrões como o do XOR
- Hype causou o AI Winter



não é linearmente separável !



LINHA DO TEMPO


1958	Perceptron
1960-1965	Teoria da Complexidade Algorítmica (Solomonoff, Chaitin, Kolmogorov)
1962	Análise teórica do Perceptron
1965-1980	Teoria do Aprendizado Estatístico (Vapnik e Chervonenkis)
1967	Aparição do algoritmo k-Means
1967	Consistência do algoritmo k-NN

AI WINTER!



1984	Árvores de Decisão e Regressão (Breiman, Friedman)
1986	Ressureição das Redes Neurais: algoritmo Backpropagation
1989	Redes Neurais para reconhecer Zip Codes (CEPs)
1992-1995	Support Vector Machines (SVM)
1995	Boosting (ensemble)
1995	Aplicações: text mining, genômica, detecção de fraudes...
1998	Filtragem de Spam
2002	Análise de sentimento
2005	Carros autônomos
2008	Deep Learning e aplicações (imagem, voz, tradução)


TIPOS DE ML





APRENDIZADO SUPERVISIONADO




**Algoritmo de
aprendizado**



APRENDIZADO SUPERVISIONADO



gato e cachorro



APRENDIZADO SUPERVISIONADO



- Exemplos de treinamento $(x_1, y_1), \dots, (x_n, y_n), \dots$
- Encontrar $f(x)$ tal que $y_i \sim f(x_i)$
- Classificação: y é discreto
- Regressão: y é um número real



APRENDIZADO NÃO-SUPERVISIONADO

- Exemplos x_1, \dots, x_n
- Não-categoria de aprendizado : complemento de aprendizado supervisionado
- Exemplos : clustering, redução de dimensionalidade, aprendizado de representações
- Descoberta de padrões interessantes nos dados




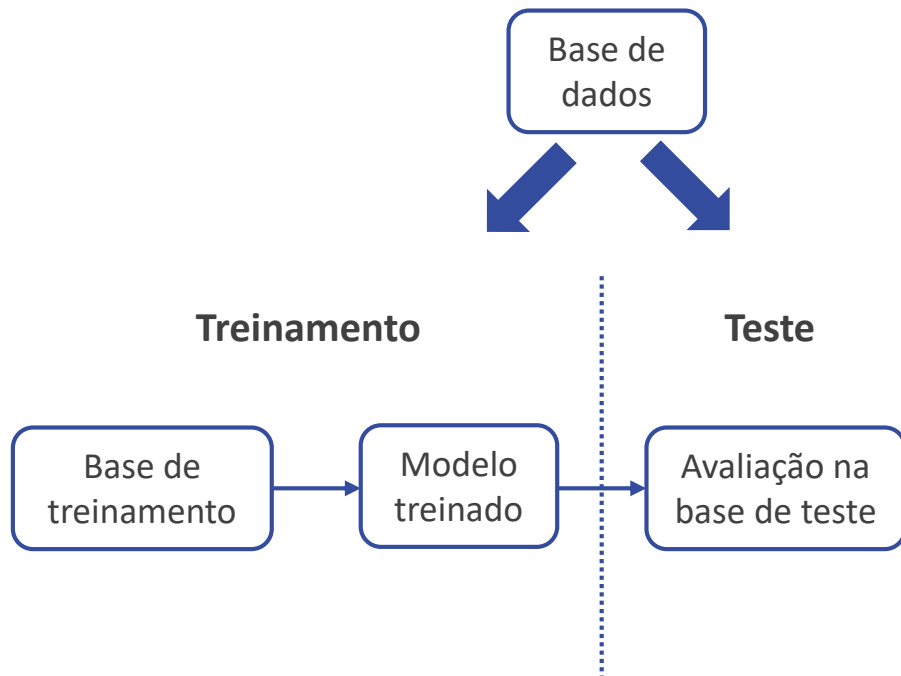
APRENDIZADO POR REFORÇO

- Encontrar estratégia (ações) que maximiza retorno (*reward*) e minimiza punição
- Delayed feedback: retorno de uma ação não é conhecido
- *Exploration vs. exploitation*
- Problema típico: multi-armed bandits;
- Aplicações: robótica, jogos



APRENDIZADO SUPERVISIONADO





EXEMPLO : PERCEPTRON

Algoritmo de treinamento começa com w *aleatório* e percorre os exemplos $(x_1, d_1), \dots, (x_k, d_k)$ – x_i pertence a R^k e d_k a $\{-1, +1\}$:

1. Se o exemplo x_i é corretamente classificado, ou seja, o valor predito y_i é igual ao valor esperado d_i , o vetor de pesos w não sofre alterações
2. Se o exemplo x_i é incorretamente classificado, então w sofre alterações proporcionalmente a uma taxa de aprendizado η :


$$w \leftarrow w + \eta(d_i - y_i) \cdot x_i$$

REFLEXÃO...




Bom desempenho durante o treinamento
reflete um bom modelo ?

OVERFITTING E UNDERFITTING




OVERFITTING E UNDERFITTING NA CLASSIFICAÇÃO


Underfitting



Optimal solution




Overfitting



OVERFITTING


- Super ajuste de parâmetros do modelo : memorização vs generalização
- Em redes neurais por exemplo : aumento indiscriminado de camadas e neurônios
- Durante treinamento o erro tende a ser baixo e durante o teste o erro tende a ser alto




Topologia 1 : com overfitting
Topologia 2 : sem overfitting

UNDERFITTING

- Sub ajuste parâmetros do modelo e o mesmo não é capaz de aprender adequadamente
- Durante treinamento e teste o erro tende a ser baixo

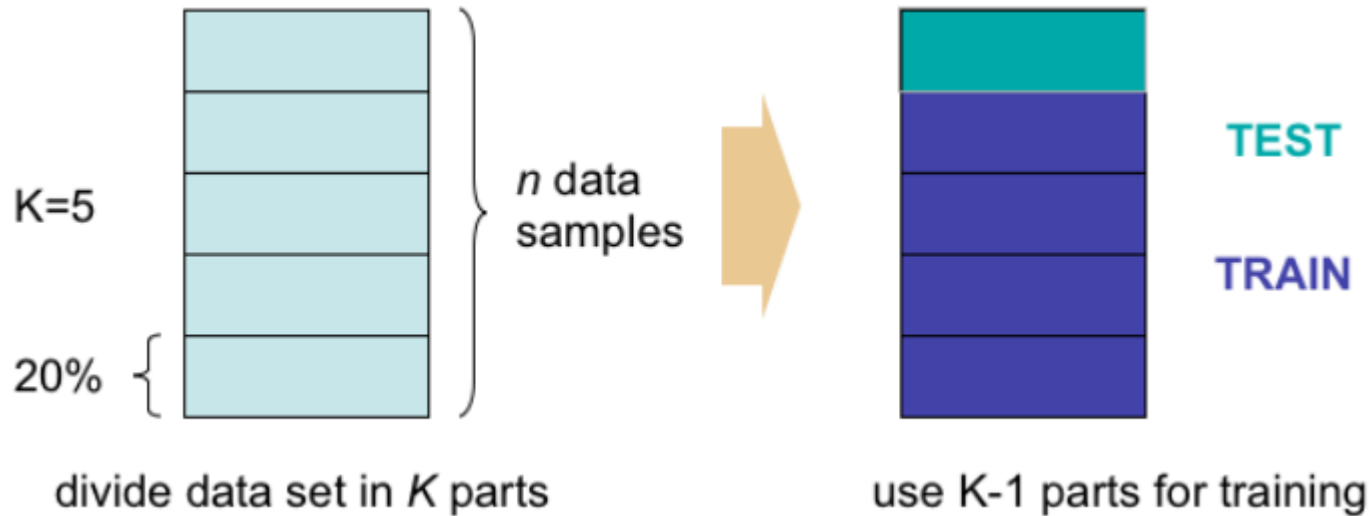


Underfitted




Good Fit/Robust

VALIDAÇÃO CRUZADA : K-FOLD

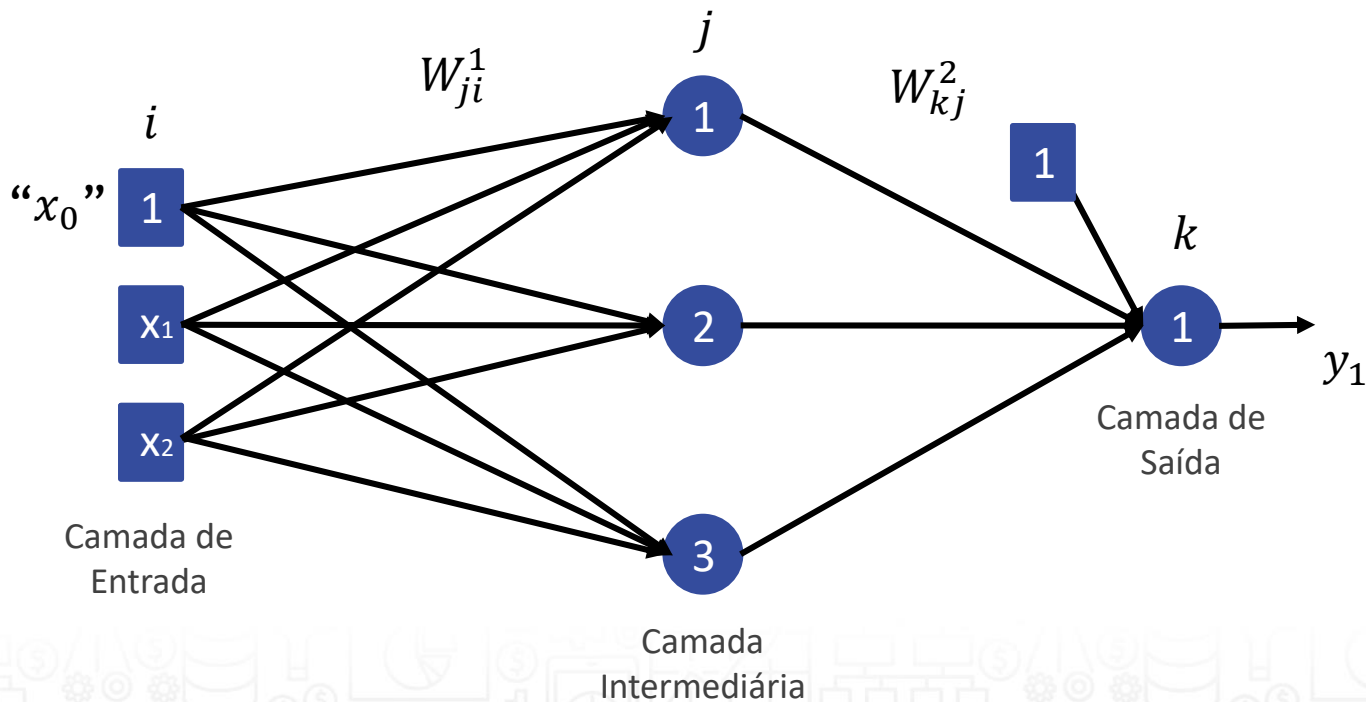


PERCEPTRON MULTICAMADAS




ESTRUTURA

- Dataset com duas entradas e uma saída (regressão)
- Topologia com uma camada escondida e 3 neurônios
- W_{ji} é a matriz de pesos entre um elemento j e elementos i




ESTRUTURA

- Exemplo de pesos da matriz W



ESTRUTURA


- Saída dos neurônios



FUNÇÕES DE ATIVAÇÃO


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



tanh


$$\tanh(x)$$



NORMALIZAÇÃO E PADRONIZAÇÃO


- Motivação :
 - Ter a mesma escala no processo de treinamento
 - Saturação das funções de ativação

Normalização




Padronização

$$x_{ipad} = \frac{x_i - \mu}{\sigma}$$

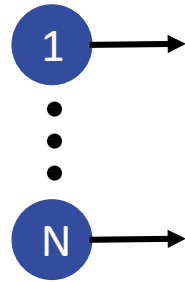


ATUALIZAÇÃO DOS PESOS

- $E(k)$: erro associado a uma amostra k : (x_1, x_2)
- $d(k)$: a saída esperada em relação à amostra k
- Pesos são atualizados em função do gradiente negativo do erro


$$E(k) = \frac{1}{2} (y_1 - d_1)^2$$


Para 1 saída


$$E(k) = \frac{1}{2} \sum_{n=1}^N (y_n(k) - d_n(k))^2$$

Para N saídas


$$W'_{ij} \propto -\nabla E$$

SUPERFÍCIE DE ERRO




CLASSIFICAÇÃO


- Uma camada escondida é capaz de classificar problemas convexos (neurônios adicionam arestas)
- Problemas não convexos podem ser classificados com mais camadas escondidas
- Resolve o problema do XOR




convex




concave



2 neurônios na
camada escondida




4 neurônios na
camada escondida



2 regiões convexas
2 camadas escondidas
(3 neurônios cada)

ÁRVORES DE DECISÃO



CARACTERÍSTICAS


categórico

categórico

contínuo

classe

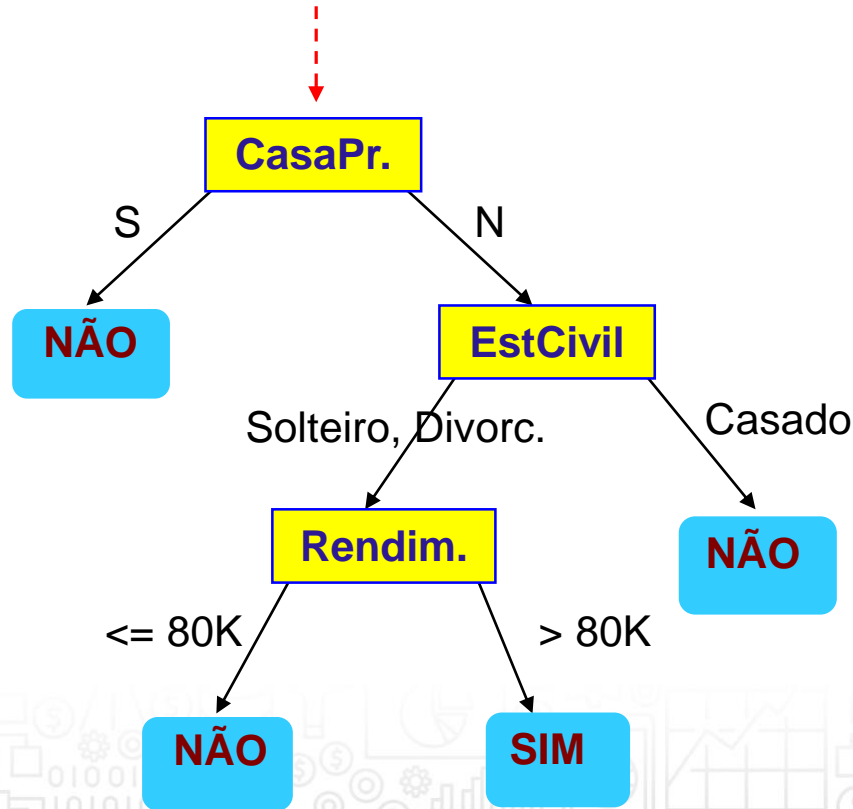
Id	Casa própria	EstCivil	Rendim.	Mau Pagador
1	S	Solteiro	125K	NÃO
2	N	Casado	100K	NÃO
3	N	Solteiro	70K	NÃO
4	S	Casado	120K	NÃO
5	N	Divorc.	95K	SIM
6	N	Casado	60K	NÃO
7	S	Divorc.	220K	NÃO
8	N	Solteiro	85K	SIM
9	N	Casado	75K	NÃO
10	N	Solteiro	90K	SIM



Pode haver mais de uma árvore para o mesmo conjunto de dados!!!

PREVISÃO COM O MODELO

Comece pela raiz da árvore!



Dado para teste

Casa Própria	Estado Civil	Rendim.	Mau pagador
N	Casado	80K	?

- Há diversos algoritmos para construção de árvores que fazem uso de diferentes funções objetivas
- Ex de algoritmos : ID3, C3.5, CART, SPRINT
- Ex de funções objetivas : entropia, índice de gini

Entropia

$$E(S) = - \sum_{i=1}^n p_i \log_2 p_i$$

- S : número de registros
- n : número de valores possíveis de cada classe
- p_i : proporção das amostras de cada classe i em relação ao total de amostras

Ganho de informação

$$G(S, A) = E(S) - \sum_{i=1}^n \frac{|S_V|}{|S|} E(s)$$

- $G(S, A)$: ganho do atributo a sobre o conjunto S
- S_v : subconjunto S para um valor do atributo A
- $|S_v|$: número de elementos de S_v
- $|S|$: número de elementos de S

ID3 : NÓ RAIZ

caso	montante	idade	salário	conta	empréstimo
1	médio	sênior	baixo	sim	<i>não</i>
2	médio	sênior	baixo	não	<i>não</i>
3	baixo	sênior	baixo	sim	<i>sim</i>
4	alto	média	baixo	sim	<i>sim</i>
5	alto	jovem	alto	sim	<i>sim</i>
6	alto	jovem	alto	não	<i>não</i>
7	baixo	jovem	alto	não	<i>sim</i>
8	médio	média	baixo	sim	<i>não</i>
9	médio	jovem	alto	sim	<i>sim</i>
10	alto	média	alto	sim	<i>sim</i>
11	médio	média	alto	não	<i>sim</i>
12	baixo	jovem	baixo	não	<i>sim</i>
13	baixo	sênior	alto	sim	<i>sim</i>
14	alto	média	baixo	não	<i>não</i>

ID3 : NÓ RAIZ

variável dependente



caso	montante	idade	salário	conta	empréstimo
1	médio	sênior	baixo	sim	não
2	médio	sênior	baixo	não	não
3	baixo	sênior	baixo	sim	sim
4	alto	média	baixo	sim	sim
5	alto	jovem	alto	sim	sim
6	alto	jovem	alto	não	não
7	baixo	jovem	alto	não	sim
8	médio	média	baixo	sim	não
9	médio	jovem	alto	sim	sim
10	alto	média	alto	sim	sim
11	médio	média	alto	não	sim
12	baixo	jovem	baixo	não	sim
13	baixo	sênior	alto	sim	sim
14	alto	média	baixo	não	não

$$E(S) = - \sum_{i=1}^n p_i \log_2 p_i$$

- Total de 14 amostras : $S = 14$
- $p_{\text{não}} = 5/14$
- $p_{\text{sim}} = 9/14$

$$E(S) = \left(\frac{5}{14} \log_2 \frac{5}{14} + \frac{9}{14} \log_2 \frac{9}{14} \right)$$

$$E(S) = 0,94$$

MONTANTE

- Montante = médio

montante	empréstimo
médio	<i>não</i>
médio	<i>não</i>
baixo	<i>sim</i>
alto	<i>sim</i>
alto	<i>sim</i>
alto	<i>não</i>
baixo	<i>sim</i>
médio	<i>não</i>
médio	<i>sim</i>
alto	<i>sim</i>
médio	<i>sim</i>
baixo	<i>sim</i>
baixo	<i>sim</i>
alto	<i>não</i>

$$E(S) = - \sum_{i=1}^n p_i \log_2 p_i$$

- Total de 5 amostras : $S = 5$
- $p_{\text{não}} = 3/5$
- $p_{\text{sim}} = 2/5$

$$E(S) = - \left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5} \right) = 0,971$$

MONTANTE

- Montante = baixo

montante	empréstimo
médio	<i>não</i>
médio	<i>não</i>
baixo	<i>sim</i>
alto	<i>sim</i>
alto	<i>sim</i>
alto	<i>não</i>
baixo	<i>sim</i>
médio	<i>não</i>
médio	<i>sim</i>
alto	<i>sim</i>
médio	<i>sim</i>
baixo	<i>sim</i>
baixo	<i>sim</i>
alto	<i>não</i>

$$E(S) = - \sum_{i=1}^n p_i \log_2 p_i$$

- Total de 4 amostras : $S = 4$
- $p_{\text{não}} = 0/4$
- $p_{\text{sim}} = 4/4$

Entropia 0 : fácil separar as classes

$$E(S) = - \left(\frac{0}{4} \log_2 \frac{0}{4} + \frac{4}{4} \log_2 \frac{4}{4} \right) = 0$$

MONTANTE

- Montante = alto

montante	empréstimo
médio	<i>não</i>
médio	<i>não</i>
baixo	<i>sim</i>
alto	<i>sim</i>
alto	<i>sim</i>
alto	<i>não</i>
baixo	<i>sim</i>
médio	<i>não</i>
médio	<i>sim</i>
alto	<i>sim</i>
médio	<i>sim</i>
baixo	<i>sim</i>
baixo	<i>sim</i>
alto	<i>não</i>

$$E(S) = - \sum_{i=1}^n p_i \log_2 p_i$$

- Total de 5 amostras : $S = 5$
- $p_{\text{não}} = 2/5$
- $p_{\text{sim}} = 3/5$

$$E(S) = - \left(\frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5} \right) = 0,971$$

MONTANTE

- Ganho de informação

$$G(S, A) = E(S) - \sum_{i=1}^n \frac{|S_V|}{|S|} E(s)$$

E(Montante = Médio)	E(Montante = Baixo)	E(Montante = Alto)	E(S)
0,971	0	0,971	0,94

$$G(S, Montante) = 0,94 - \left(\frac{5}{14} 0,971 + \frac{4}{14} 0 + \frac{5}{14} 0,971 \right) = 0,246$$

DEMAIS VARIÁVEIS


Maior ganho de informação!

$$G(S, Montante) = 0,246$$


$$G(S, Idade) = 0,049$$

$$G(S, Salário) = 0,151$$

$$G(S, Conta) = 0,047$$

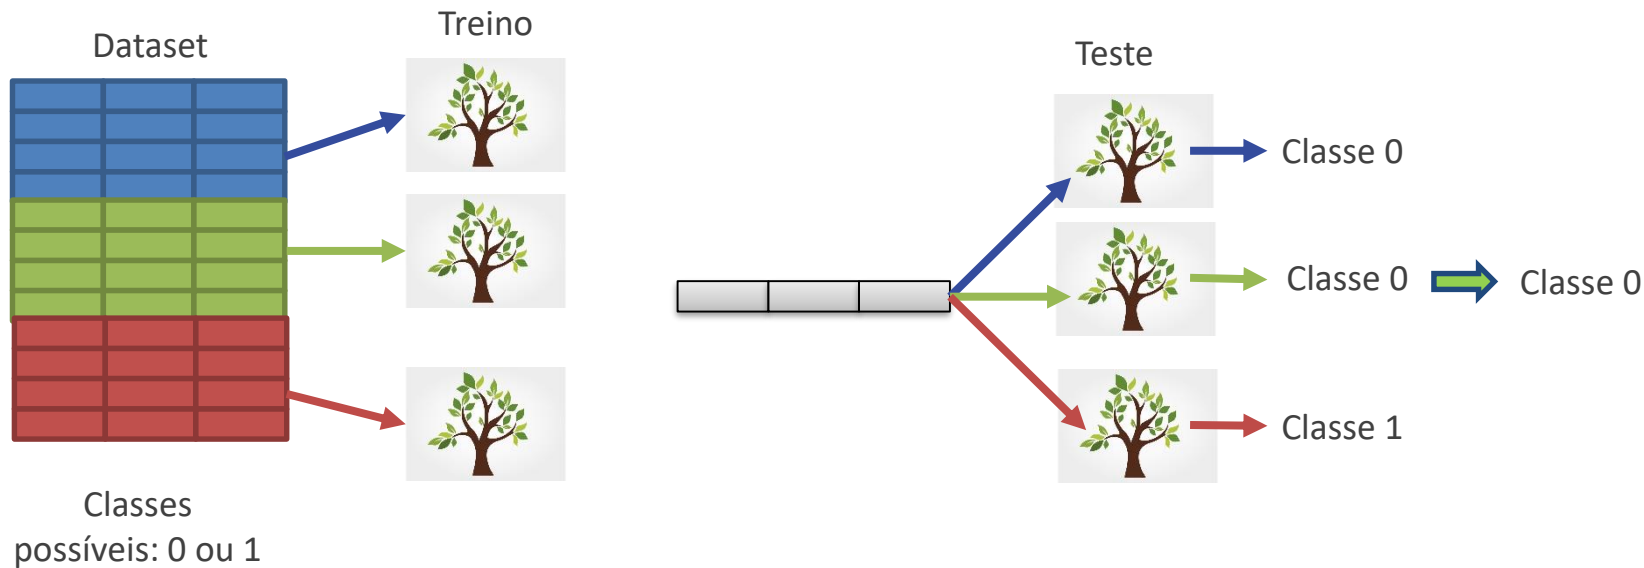


CONTINUANDO...



RANDOM FOREST


- Algoritmo de Ensemble
- Utiliza bagging de árvores de decisão : faz uma combinação das saídas de cada árvore treinada



PRA SABER MAIS...

- ✓ Lista dataelixir.com
- ✓ Lista datahackers.com.br
- ✓ Kaggle
- ✓ Coursera





WE'RE HIRING !

E-mails:

- igor.braga@bigdata.com.br
- igor.martinelli@bigdata.com.br
- mateus.pedrino@bigdata.com.br



Processo Seletivo:

- tinyurl.com/estagiobigdata
- tinyurl.com/dsbigdata